

Tolerância a Falhas em Clusters Spot — Resultados dos Experimentos

Benchmarks: NAS Parallel Benchmarks · LU Classe C · EP Classe D · CG Classe C

Cluster: AWS m5.xlarge workers (2 e 4 nós) · us-west-2

1. Visão Geral


Este relatório analisa os resultados de 24 execuções em três benchmarks (LU, EP, CG), dois tamanhos de cluster (2 e 4 workers) e quatro estratégias de tolerância a falhas:

Estratégia	Descrição
noFT (nativo)	MPI puro, sem MANA, sem tolerância a falhas
MANA noFT	Camada de interposição MANA ativa, nenhuma falha injetada
REPLACE	MANA FT: nó com falha é substituído por uma nova instância EC2
DEGRADED	MANA FT: o trabalho continua com um processo a menos após a falha

Cada execução com tolerância a falhas (FT) teve uma falha injetada em um tempo fixo, garantindo que o momento da falha fosse reproduzível entre as estratégias. Foram realizadas somente 1 repetição em cada cenário.

2. Tempo Total de Execução

PROF




Valores brutos do tempo de execução (segundos):

Benchmark	Workers	noFT	MANA noFT	REPLACE	DEGRADED
CG Classe C	2w	34.3	107.2	283.4	170.4
CG Classe C	4w	20.9	32.8	256.8	93.7
EP Classe D	2w	330.5	492.6	583.7	537.4

Benchmark	Workers	noFT	MANA noFT	REPLACE	DEGRADED
EP Classe D	4w	167.0	249.0	409.1	294.6
LU Classe C	2w	146.9	242.1	397.3	302.3
LU Classe C	4w	80.7	134.6	360.1	190.2

Os três benchmarks acabaram abrangendo tempo muito diferentes: O CG Classe C termina em menos de 35 segundos nativamente, o LU em cerca de 2,5 minutos, e o EP Classe D em mais de 5 minutos. Mas acredito que essa variação pode ser útil porque revela como o tempo de recuperação se comporta em relação à duração do trabalho.

3. Custo Adicional de Desempenho (Overhead) do MANA



Overhead do MANA ($\text{MANA noFT} \div \text{noFT}$):


Benchmark	2 workers	4 workers
CG Classe C	3.13×	1.57×
EP Classe D	1.49×	1.49×
LU Classe C	1.65×	1.67×

PROF

Os resultados expõem um padrão claro baseado na intensidade de comunicação:

- **EP Classe D:** Apresenta o overhead mais baixo e consistente ($\sim 1.49\times$), independentemente do tamanho do cluster. Como os processos EP têm comunicação entre processos quase nula, o custo de interceptação do MANA é mínimo e fixo por processo.
- **LU Classe C:** Mostra um overhead estável de $\sim 1.66\times$, um pouco maior que o EP, mas consistente com 2 e 4 workers. Os padrões de comunicação no LU são estruturados e previsíveis.
- **CG Classe C:** Apresenta $1.57\times$ com 4 workers, consistente com os outros benchmarks. Porém, o resultado com 2 workers ($3.13\times$) é uma suspeita de anomalia isolada. Vamos ver se com mais repetições esse número irá se manter.

4. Analisando as Fases de Recuperação de Falhas



A recuperação é dividida em três fases:

Fase	Definição	Fator principal
Fase 1	Detecção da falha → checkpoint salvo	Tamanho do checkpoint / intervalo de poll do watcher
Fase 2	Checkpoint salvo → despachado do restart	Provisionamento de instância AWS (REPLACE) ou setup de reinício (DEGRADED)
Fase 3	início do restart → conclusão	Computação restante + mudança na quantidade de processos

Tempos medidos por fase (segundos):

Benchmark	Workers	Estratégia	Fase 1	Fase 2	Fase 3	Recuperação Total
CG C	2w	REPLACE	26.6	190.6	53.7	271.0
CG C	2w	DEGRADED	26.6	23.1	110.3	160.0
CG C	4w	REPLACE	26.5	185.4	38.1	250.0
CG C	4w	DEGRADED	26.6	21.7	36.9	85.2
EP D	2w	REPLACE	16.3	196.4	314.7	527.4
EP D	2w	DEGRADED	16.3	21.7	444.4	482.4
EP D	4w	REPLACE	16.4	185.6	151.5	353.5
EP D	4w	DEGRADED	16.3	21.6	205.0	243.0
LU C	2w	REPLACE	26.5	185.0	130.5	342.0
LU C	2w	DEGRADED	26.6	21.7	198.9	247.2
LU C	4w	REPLACE	26.5	220.9	57.5	305.0
LU C	4w	DEGRADED	26.5	21.6	88.8	136.9

Principais observações:

A **Fase 1** depende do tamanho do checkpoint do benchmark, não da estratégia:

- LU e CG: ~26.5 s (maior uso de memória, mais dados para gravar no checkpoint).
- EP: ~16.3 s (embarçosamente paralelo, cada processo guarda um estado menor e independente).


A **Fase 2** é inteiramente determinada pela infraestrutura:

- DEGRADED: **~21–23 s** em todos os benchmarks e tamanhos de cluster — puramente o tempo de ler o checkpoint e reiniciar com um processo a menos.
- REPLACE: **~185–221 s**, dominado pelo tempo de provisionamento da instância AWS EC2 (boot, inicialização da AMI, conexão com o Slurm).

A **Fase 3** é onde as estratégias divergem pela carga de trabalho:

- Para **trabalhos curtos (CG)**: A Fase 3 do DEGRADED é maior, deixando ~98% do trabalho restante para uma quantidade reduzida de processos. Apesar disso, a recuperação total do DEGRADED (85–160 s) ainda é bem menor que a do REPLACE (250–271 s) porque a Fase 2 domina o custo do REPLACE.
- Para **trabalhos longos (EP)**: A penalidade da Fase 3 do DEGRADED é proporcionalmente grande (444 s para 2w) porque o EP é embarçosamente paralelo, perder 1 de 4 processos significa que os 3 processos restantes precisam cobrir 33% a mais de trabalho cada. A Fase 3 do REPLACE (315 s) é mais curta porque restaura a contagem total de processos antes de continuar.

5. Comparação Direta: REPLACE vs DEGRADED



PROF

Custo extra (overhead) FT relativo à base MANA noFT:

Benchmark	Workers	Overhead REPLACE	Overhead DEGRADED
CG Classe C	2w	2.64×	1.59×
CG Classe C	4w	7.83×	2.86×
EP Classe D	2w	1.18×	1.09×
EP Classe D	4w	1.64×	1.18×
LU Classe C	2w	1.64×	1.25×
LU Classe C	4w	2.68×	1.41×

O DEGRADED supera consistentemente o REPLACE em todos os benchmarks e tamanhos de cluster. A vantagem do DEGRADED é mais evidente para trabalhos curtos como o CG, onde a Fase 2 do REPLACE

(~185–220 s) pesa muito na duração total do trabalho.


Dessa forma, para o EP Classe D com 2 workers, ambas as estratégias se aproximam ($1.18\times$ vs $1.09\times$) porque a longa Fase 3 do DEGRADED compensa parcialmente a economia de tempo da Fase 2.

Isso indica que para workloads mais longo, o REPLACE acaba sendo o mais indicado, enquanto para workloads curtos o DEGRADED passa a ser mais interessante.

A teoriase se confirma quando observamos o resultado do CG 4w REPLACE ($7.83\times$), onde representa um caso extremo: um trabalho de 20.9 s sofrendo um atraso de recuperação de ~251 s, com os custos de infraestrutura dominando completamente.

Assim, a estratégias REPLACE para trabalhos paralelos de curta duração em infraestrutura de nuvem, se mostra não ser uma escolha inteligente.


6. Escalabilidade



Escalar de 2 para 4 workers reduz o tempo de execução para todas as estratégias. E aparenta ser linear.

7. Análise Financeira e de Custos

PROF



Modelo de precificação:

- noFT (nativo): todos os nós sob demanda (on-demand).
- REPLACE / DEGRADED: workers em spot (desconto de ~70% para m5.xlarge: \$0.0585/h vs \$0.1920/h on-demand); nó principal (head node) on-demand.

Custo por execução (USD), cluster de 4 workers:

Benchmark	noFT On-Demand	DEGRADED Spot	Economia
-----------	----------------	---------------	----------

Benchmark	noFT On-Demand	DEGRADED Spot	Economia
CG Classe C	\$0.0049	\$0.0083	−67% (mais caro)
LU Classe C	\$0.0191	\$0.0168	+12%
EP Classe D	\$0.0395	\$0.0260	+34%

O custo financeiro para tolerância a falhas com instâncias spot aparenta depender da duração do trabalho:

- **Trabalhos curtos (CG Classe C, ~35 s):** O desconto do spot não compensa o tempo de recuperação adicionado pelo DEGRADED (+73 s). Rodar o noFT no modelo on-demand é mais rápido e mais barato. FT não tem bom custo-benefício para trabalhos dessa duração.
- **Trabalhos médios (LU Classe C, ~150 s):** DEGRADED no spot é ligeiramente mais barato (12% de economia) ao mesmo tempo em que fornece recuperação de falhas. O ponto de equilíbrio (break-even) é visível aqui.
- **Trabalhos mais longos (EP Classe D, ~300 s):** O desconto do spot domina, tornando o DEGRADED 34% mais barato que o noFT on-demand, tolerando também falhas nos nós. Este é o cenário onde a estratégia entrega valor claro.

Nos casos observados, a estratégia REPLACE não é competitiva em custo em nenhum benchmark: seu tempo da Fase 2 (~185–220 s) inflaciona o tempo total além do ponto em que a economia com spot possa compensar.

Mas talvez para workloads mais longos ainda, passa a compensar.

8. Conclusões

Os resultados experimentais dos benchmarks LU, EP e CG demonstram que reiniciar de um checkpoint baseado em MANA é um mecanismo viável de tolerância a falhas para cargas de trabalho MPI em clusters spot na nuvem, com alguns pontos importantes ligados à duração do trabalho e ao padrão de comunicação.

Principais descobertas:

1. **Impacto inerente da ferramenta:** A execução através do MANA, mesmo sem a ocorrência de falhas, já introduz um overhead de ~1.5x no tempo de execução da aplicação.
2. **Tempo de salvamento (Fase 1):** O tempo gasto para a preparação e gravação do checkpoint depende exclusivamente da quantidade de dados em memória que precisam ser gravados no arquivo de restauração, e não da estratégia adotada.
3. **REPLACE vs. DEGRADED:** A eficiência da estratégia de recuperação depende da duração da tarefa. A estratégia DEGRADED se mostra muito superior para workloads curtos e médios (pois evita o tempo de provisionamento de infraestrutura). Já a estratégia REPLACE só começa a ser indicada para workloads longos, onde o tempo gasto subindo uma nova máquina se paga ao restaurar o poder total de processamento.

4. **Viabilidade Econômica:** A utilização de tolerância a falhas compensa financeiramente graças aos altos descontos das instâncias Spot. A única exceção são os workloads muito curtos, onde o tempo de atraso da recuperação da falha acaba anulando a economia gerada pelo uso do modelo Spot.