

# Tolerância a Falhas em Clusters Spot — Resultados dos Experimentos

Benchmarks: NAS Parallel Benchmarks · LU Classe C · EP Classe D · CG Classe C

Cluster: AWS m5.xlarge workers (2 e 4 nós) · us-west-2

## 1. Visão Geral


Este relatório analisa os resultados de 24 execuções em três benchmarks (LU, EP, CG), dois tamanhos de cluster (2 e 4 workers) e quatro estratégias de tolerância a falhas:

| Estratégia    | Descrição                                                         |
|---------------|-------------------------------------------------------------------|
| noFT (nativo) | MPI puro, sem MANA, sem tolerância a falhas                       |
| MANA noFT     | Camada de interposição MANA ativa, nenhuma falha injetada         |
| REPLACE       | MANA FT: nó com falha é substituído por uma nova instância EC2    |
| DEGRADED      | MANA FT: o trabalho continua com um processo a menos após a falha |

Cada execução com tolerância a falhas (FT) teve uma falha injetada em um tempo fixo, garantindo que o momento da falha fosse reproduzível entre as estratégias. Foram realizadas somente 1 repetição em cada cenário.

## 2. Tempo Total de Execução

PROF




Valores brutos do tempo de execução (segundos):

| Benchmark   | Workers | noFT  | MANA noFT | REPLACE | DEGRADED |
|-------------|---------|-------|-----------|---------|----------|
| CG Classe C | 2w      | 34.3  | 107.2     | 283.4   | 170.4    |
| CG Classe C | 4w      | 20.9  | 32.8      | 256.8   | 93.7     |
| EP Classe D | 2w      | 330.5 | 492.6     | 583.7   | 537.4    |

| Benchmark   | Workers | noFT  | MANA noFT | REPLACE | DEGRADED |
|-------------|---------|-------|-----------|---------|----------|
| EP Classe D | 4w      | 167.0 | 249.0     | 409.1   | 294.6    |
| LU Classe C | 2w      | 146.9 | 242.1     | 397.3   | 302.3    |
| LU Classe C | 4w      | 80.7  | 134.6     | 360.1   | 190.2    |

Os três benchmarks acabaram abrangendo tempo muito diferentes: O CG Classe C termina em menos de 35 segundos nativamente, o LU em cerca de 2,5 minutos, e o EP Classe D em mais de 5 minutos. Mas acredito que essa variação pode ser útil porque revela como o tempo de recuperação se comporta em relação à duração do trabalho.

### 3. Custo Adicional de Desempenho (Overhead) do MANA



**Overhead do MANA ( $\text{MANA noFT} \div \text{noFT}$ ):**


| Benchmark   | 2 workers    | 4 workers |
|-------------|--------------|-----------|
| CG Classe C | <b>3.13×</b> | 1.57×     |
| EP Classe D | 1.49×        | 1.49×     |
| LU Classe C | 1.65×        | 1.67×     |

PROF

Os resultados expõem um padrão claro baseado na intensidade de comunicação:

- **EP Classe D:** Apresenta o overhead mais baixo e consistente (~1.49×), independentemente do tamanho do cluster. Como os processos EP têm comunicação entre processos quase nula, o custo de interceptação do MANA é mínimo e fixo por processo.
- **LU Classe C:** Mostra um overhead estável de ~1.66×, um pouco maior que o EP, mas consistente com 2 e 4 workers. Os padrões de comunicação no LU são estruturados e previsíveis.
- **CG Classe C:** Apresenta 1.57× com 4 workers, consistente com os outros benchmarks. Porém, o resultado com 2 workers (3.13×) é uma suspeita de anomalia isolada. Vamos ver se com mais repetições esse número irá se manter.

### 4. Analisando as Fases de Recuperação de Falhas



A recuperação é dividida em três fases:

| Fase   | Definição                                | Fator principal                                                            |
|--------|------------------------------------------|----------------------------------------------------------------------------|
| Fase 1 | Detecção da falha → checkpoint salvo     | Tamanho do checkpoint / intervalo de poll do watcher                       |
| Fase 2 | Checkpoint salvo → despachado do restart | Provisionamento de instância AWS (REPLACE) ou setup de reinício (DEGRADED) |
| Fase 3 | início do restart → conclusão            | Computação restante + mudança na quantidade de processos                   |

Tempos medidos por fase (segundos):

| Benchmark | Workers | Estratégia | Fase 1 | Fase 2 | Fase 3 | Recuperação Total |
|-----------|---------|------------|--------|--------|--------|-------------------|
| CG C      | 2w      | REPLACE    | 26.6   | 190.6  | 53.7   | 271.0             |
| CG C      | 2w      | DEGRADED   | 26.6   | 23.1   | 110.3  | 160.0             |
| CG C      | 4w      | REPLACE    | 26.5   | 185.4  | 38.1   | 250.0             |
| CG C      | 4w      | DEGRADED   | 26.6   | 21.7   | 36.9   | 85.2              |
| EP D      | 2w      | REPLACE    | 16.3   | 196.4  | 314.7  | 527.4             |
| EP D      | 2w      | DEGRADED   | 16.3   | 21.7   | 444.4  | 482.4             |
| EP D      | 4w      | REPLACE    | 16.4   | 185.6  | 151.5  | 353.5             |
| EP D      | 4w      | DEGRADED   | 16.3   | 21.6   | 205.0  | 243.0             |
| LU C      | 2w      | REPLACE    | 26.5   | 185.0  | 130.5  | 342.0             |
| LU C      | 2w      | DEGRADED   | 26.6   | 21.7   | 198.9  | 247.2             |
| LU C      | 4w      | REPLACE    | 26.5   | 220.9  | 57.5   | 305.0             |
| LU C      | 4w      | DEGRADED   | 26.5   | 21.6   | 88.8   | 136.9             |

Principais observações:

A **Fase 1** depende do tamanho do checkpoint do benchmark, não da estratégia:

- LU e CG: ~26.5 s (maior uso de memória, mais dados para gravar no checkpoint).
- EP: ~16.3 s (embarçosamente paralelo, cada processo guarda um estado menor e independente).


A **Fase 2** é determinada pela infraestrutura:

- DEGRADED: **~21–23 s** em todos os benchmarks e tamanhos de cluster, tempo de ler o checkpoint e reiniciar com um processo a menos.
- REPLACE: **~185–221 s**, dominado pelo tempo de provisionamento da instância AWS EC2 (boot, inicialização da AMI, conexão com o Slurm).

A **Fase 3** é onde as estratégias divergem pela carga de trabalho:

- Para **trabalhos curtos (CG)**: A Fase 3 do DEGRADED é maior, deixando ~98% do trabalho restante para uma quantidade reduzida de processos. Apesar disso, a recuperação total do DEGRADED (85–160 s) ainda é bem menor que a do REPLACE (250–271 s) porque a Fase 2 domina o custo do REPLACE.
- Para **trabalhos longos (EP)**: A penalidade da Fase 3 do DEGRADED é proporcionalmente grande (444 s para 2w) porque o EP é embarçosamente paralelo, perder 1 de 4 processos significa que os 3 processos restantes precisam cobrir 33% a mais de trabalho cada. A Fase 3 do REPLACE (315 s) é mais curta porque restaura a contagem total de processos antes de continuar.

## 5. Comparação Direta: REPLACE vs DEGRADED



PROF

**Custo extra (overhead) FT relativo à base MANA noFT:**

| Benchmark   | Workers | Overhead REPLACE | Overhead DEGRADED |
|-------------|---------|------------------|-------------------|
| CG Classe C | 2w      | 2.64×            | 1.59×             |
| CG Classe C | 4w      | <b>7.83×</b>     | 2.86×             |
| EP Classe D | 2w      | 1.18×            | <b>1.09×</b>      |
| EP Classe D | 4w      | 1.64×            | 1.18×             |
| LU Classe C | 2w      | 1.64×            | 1.25×             |
| LU Classe C | 4w      | 2.68×            | 1.41×             |

O DEGRADED supera consistentemente o REPLACE em todos os benchmarks e tamanhos de cluster. A vantagem do DEGRADED é mais evidente para trabalhos curtos como o CG, onde a Fase 2 do REPLACE

(~185–220 s) pesa muito na duração total do trabalho.

Dessa forma, para o EP Classe D com 2 workers, ambas as estratégias se aproximam ( $1.18\times$  vs  $1.09\times$ ) porque a longa Fase 3 do DEGRADED compensa parcialmente a economia de tempo da Fase 2.


Isso indica que para workloads mais longo, o REPLACE acaba sendo o mais indicado, enquanto para workloads curtos o DEGRADED passa a ser mais interessante.

A teoriase se confirma quando observamos o resultado do CG 4w REPLACE ( $7.83\times$ ), onde representa um caso extremo: um trabalho de 20.9 s sofrendo um atraso de recuperação de ~251 s, com os custos de infraestrutura dominando completamente.

Assim, a estratégias REPLACE para trabalhos paralelos de curta duração em infraestrutura de nuvem, se mostra não ser uma escolha inteligente.

---

## 6. Escalabilidade




Escalar de 2 para 4 workers reduz o tempo de execução para todas as estratégias. E aparenta ser linear.

---

## 7. Análise Financeira e de Custos

PROF



### Modelo de precificação:

- noFT (nativo): todos os nós sob demanda (on-demand).
- REPLACE / DEGRADED: workers em spot (desconto de ~70% para m5.xlarge: \$0.0585/h vs \$0.1920/h on-demand); nó principal (head node) on-demand.

### Custo por execução (USD), cluster de 4 workers:

---

| Benchmark | noFT On-Demand | DEGRADED Spot | Economia |
|-----------|----------------|---------------|----------|
|-----------|----------------|---------------|----------|

---

| Benchmark   | noFT On-Demand | DEGRADED Spot | Economia         |
|-------------|----------------|---------------|------------------|
| CG Classe C | \$0.0049       | \$0.0083      | −67% (mais caro) |
| LU Classe C | \$0.0191       | \$0.0168      | <b>+12%</b>      |
| EP Classe D | \$0.0395       | \$0.0260      | <b>+34%</b>      |

O custo financeiro para tolerância a falhas com instâncias spot aparenta depender da duração do trabalho:

- **Trabalhos curtos (CG Classe C, ~35 s):** O desconto do spot não compensa o tempo de recuperação adicionado pelo DEGRADED (+73 s). Rodar o noFT no modelo on-demand é mais rápido e mais barato. FT não tem bom custo-benefício para trabalhos dessa duração.
- **Trabalhos médios (LU Classe C, ~150 s):** DEGRADED no spot é ligeiramente mais barato (12% de economia) ao mesmo tempo em que fornece recuperação de falhas. O ponto de equilíbrio (break-even) é visível aqui.
- **Trabalhos mais longos (EP Classe D, ~300 s):** O desconto do spot domina, tornando o DEGRADED 34% mais barato que o noFT on-demand, tolerando também falhas nos nós. Este é o cenário onde a estratégia entrega valor claro.

Nos casos observados, a estratégia REPLACE não é competitiva em custo em nenhum benchmark: seu tempo da Fase 2 (~185–220 s) inflaciona o tempo total além do ponto em que a economia com spot possa compensar.

Mas talvez para workloads mais longos ainda, passa a compensar.

## 8. Conclusões

Os resultados experimentais dos benchmarks LU, EP e CG demonstram que reiniciar de um checkpoint baseado em MANA é um mecanismo viável de tolerância a falhas para cargas de trabalho MPI em clusters spot na nuvem, com alguns pontos importantes ligados à duração do trabalho e ao padrão de comunicação.

### Principais descobertas:

1. **Impacto inerente da ferramenta:** A execução através do MANA, mesmo sem a ocorrência de falhas, já introduz um overhead de ~1.5x no tempo de execução da aplicação.
2. **Tempo de salvamento (Fase 1):** O tempo gasto para a preparação e gravação do checkpoint depende exclusivamente da quantidade de dados em memória que precisam ser gravados no arquivo de restauração, e não da estratégia adotada.
3. **REPLACE vs. DEGRADED:** A eficiência da estratégia de recuperação depende da duração da tarefa. A estratégia DEGRADED se mostra muito superior para workloads curtos e médios (pois evita o tempo de provisionamento de infraestrutura). Já a estratégia REPLACE só começa a ser indicada para workloads longos, onde o tempo gasto subindo uma nova máquina se paga ao restaurar o poder total de processamento.

4. **Viabilidade Econômica:** A utilização de tolerância a falhas compensa financeiramente graças aos altos descontos das instâncias Spot. A única exceção são os workloads muito curtos, onde o tempo de atraso da recuperação da falha acaba anulando a economia gerada pelo uso do modelo Spot.